

Proyecto final integrador · Fase 4

Factores sociodemográficos y su asociación con factores de riesgo cardiovascular, utilizando la Encuesta Nacional de Salud (ENS) 2016-2017 de Chile.

MCDI500 · Programación para la Ciencia de Datos · Grupo 4

Integrantes: Felipe Díaz Toro, Ninoska Yévenes Hernández, Guillermo Subiabre Chacón, Pablo Ríos Passteni
Docente: Omar Salinas

Parte 0 · Entorno y reproducibilidad

```
In [1]: import sys
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns

sns.set_theme(style="whitegrid", palette="deep")

print("REGISTRO DEL ENTORNO")
print("=" * 58)
print(f" Python      : {sys.version.split()[0]}")
print(f" NumPy       : {np.__version__}")
print(f" pandas      : {pd.__version__}")
print(f" Matplotlib  : {plt.matplotlib.__version__}")
print(f" seaborn     : {sns.__version__}")
print(f" Entorno virtual activo: {sys.prefix != sys.base_prefix}")
```

REGISTRO DEL ENTORNO

```
=====
Python      : 3.13.9
NumPy       : 2.5.3
pandas      : 3.0.5
Matplotlib  : 3.11.1
seaborn     : 0.13.2
Entorno virtual activo: True
```

I. Fase 1 · El problema y los objetivos

1.1 Contexto y problema

Las enfermedades cardiovasculares son la principal causa de muerte en Chile y en el mundo. Según la Encuesta Nacional de Salud (ENS) 2016-2017 del Ministerio de Salud, la prevalencia nacional de hipertensión arterial alcanza 27,6% y la de sospecha de diabetes mellitus 12,3% en personas de 15 años y más (MINSAL, 2017). Estas cifras agregadas no informan cómo se distribuye el riesgo al interior de la población.

Problema. Se dispone de registros individuales de la ENS 2016-2017, pero no de una caracterización de cómo el perfil sociodemográfico de las personas encuestadas se asocia con los principales indicadores de riesgo cardiovascular disponibles en la encuesta.

1.2 Pregunta de investigación

¿Cómo se relacionan las condiciones sociodemográficas (edad, sexo, nivel educacional, ingreso del hogar y zona de residencia) con la presencia de hipertensión arterial, diabetes, colesterol alto, índice de masa corporal y nivel de actividad física en los participantes de la ENS 2016-2017?

1.3 Objetivo general

Caracterizar la relación entre las condiciones sociodemográficas de los participantes (edad, sexo, nivel educacional, ingreso del hogar y zona de residencia) y la presencia de hipertensión arterial, diabetes, colesterol alto, un índice de masa corporal elevado y un nivel insuficiente de actividad física en la ENS 2016-2017

1.4 Objetivos específicos

1. Comparar la prevalencia de hipertensión arterial entre los distintos grupos etarios.
2. Describir cómo varía la prevalencia de diabetes según el grupo etario y la zona de residencia.
3. Analizar la relación entre el nivel educacional y la presencia de colesterol alto.
4. Examinar la asociación entre el índice de masa corporal y el nivel de actividad física.
5. Evaluar si la relación entre edad e índice de masa corporal, en presencia de hipertensión, se mantiene al estratificar por sexo.

1.5 Alcance, restricciones y supuestos

Son tres categorías distintas y conviene no mezclarlas.

Alcance. El análisis es descriptivo y exploratorio, y se limita al conjunto de encuestados de la ENS 2016-2017 disponible tras el filtro de Fase 1-2. No incluye modelamiento predictivo ni pruebas de hipótesis formales; las asociaciones que se presentan son descriptivas, no causales.

Restricciones. La ENS tiene diseño muestral complejo (conglomerados y estratos). En este trabajo, las tasas y promedios que se citan como cifra en el texto se ponderan por el factor de expansión `Fexp_F1F2p_Corr`, para que sean comparables con las cifras oficiales de MINSAL (por ejemplo, el 27,6% de HTA citado en la introducción). Las distribuciones que se muestran directamente en los diagramas de caja y de dispersión (Figuras 2 y 3, y la exploración del Objetivo 3) se presentan sin ponderar, porque las librerías utilizadas no calculan cuartiles ponderados de forma nativa, y no corresponde ponderar observaciones individuales; en esos casos se reporta el promedio ponderado como referencia complementaria, declarado junto a cada figura. Sin embargo, no se estima varianza ni intervalos de confianza con métodos de diseño muestral (conglomerados/estratos), ya que eso requiere herramientas como el paquete `survey` de R o `samplics` de Python, fuera del alcance de este curso; por lo tanto, las diferencias que se describen son puntos estimados, no diferencias estadísticamente probadas. La variable `as27` (ingreso del hogar) tiene un 18% de valores nulos, imputados según lo documentado en Fase 2-3. El índice de masa corporal y otras variables clínicas se basan en autorreporte o medición en un único momento, sin seguimiento longitudinal.

Supuestos. Cada fila corresponde a una persona distinta. Las variables categóricas se codificaron según el libro de códigos oficial de la ENS. Los grupos etarios se construyen con cortes definidos por el equipo y declarados en la Parte IV.

II. Fase 2 · El conjunto preparado

La Fase 2 no se repite acá: se carga su resultado y se documentan las decisiones que lo produjeron.

2.1 Decisiones de preparación y su justificación

Decisión	Alternativa descartada	Razón
Conservar los registros sin ingreso (as27 / as28), marcados con bandera	Eliminar las filas	Los faltantes no son aleatorios
Imputar as27 por mediana dentro de su propio tramo (as28)	Imputar con la mediana global	Preserva la estructura por tramo de ingreso
Codificar Sexo, Zona, diabetes y colesterol con one-hot	Codificación ordinal	Son categorías nominales, sin orden
Escalar Edad, IMC e ingreso con media y desviación	Dejar las unidades originales	Requerido por Fase 3
Reclasificar GPAQ de nominal a ordinal	Tratarla como nominal	Bajo < Moderado < Alto tiene orden

Consecuencia para la Fase 4. Las dos últimas decisiones dejan el conjunto ilegible para graficar (edad e IMC centrados en cero, sexo convertido en columnas de ceros y unos). La Parte IV resuelve esto.

2.2 Carga del conjunto de la Fase 2

```
In [2]: import sys
from pathlib import Path

RAIZ = Path.cwd().parent.parent # ajusta si tu notebook no está en
sys.path.insert(0, str(RAIZ))

from src.carga import leer_archivo

datos = leer_archivo(str(RAIZ / "data" / "processed" / "ens_variabl
print(f"Conjunto de origen (F1-F2): {datos.shape[0]} filas x {datos
datos.head(3)
```

Conjunto de origen (F1-F2): 5520 filas x 16 columnas

```
Out[2]:
```

	IdEncuesta	FechaInicioF1	Edad	Sexo	Zona	HTA	di3	dis2	IMC
0	20008	2016-11-27 15:10:40	25	2	1	0.0	2	3	23.198208
1	20011	2016-11-26 15:52:49	20	2	1	0.0	2	3	26.203983
2	20012	2016-11-20 13:16:39	85	2	1	1.0	2	2	23.732346

III. Fase 3 · El núcleo algorítmico

Se integran las clases de `src/` que ya construyeron y se verifica que el pipeline reproduce exactamente el resultado oficial de la Fase 2.

3.1 El pipeline completo

```
In [3]: from src.imputadores import MarcadorNoRespuesta, EliminatorFilasNulas
from src.imputadores import PorMediana, PorMedianaDeTramo, PorModa
from src.transformadores import CodificadorOneHot, EscaladorEstandar
from src.pipeline import Pipeline

variables_categoricas = ["Sexo", "Zona", "di3", "dis2"]
variables_numericas = ["Edad", "IMC", "as27"]

pasos_limpieza = [
    MarcadorNoRespuesta("as28"),
    EliminatorFilasNulas("HTA"),
    ImputadorFlexible("IMC", PorMediana()),
    ImputadorFlexible("anos_estudio_MINSAL_1", PorMediana()),
    ImputadorFlexible("as27", PorMedianaDeTramo("as28")),
    ImputadorFlexible("GPAQ", PorModa()),
]

pasos_integracion = (
    [EliminadorColumna(col) for col in ["IdEncuesta", "FechaInicioF"]
    + [ConvertidorEntero(col) for col in ["HTA", "GPAQ"]]
    + [CodificadorOneHot(col) for col in variables_categoricas]
    + [EscaladorEstandar(col) for col in variables_numericas]
)

pipeline_completo = Pipeline(pasos_limpieza + pasos_integracion)
df_transformado = pipeline_completo.ajustar_transformar(datos)

print(f"Dimensiones iniciales : {datos.shape}")
print(f"Dimensiones finales   : {df_transformado.shape}")
```

Dimensiones iniciales : (5520, 16)

Dimensiones finales : (5511, 23)

3.2 Eficiencia computacional

Además de validar el pipeline, se comprueba brevemente el costo computacional de los transformadores propios frente a una implementación de referencia de scikit-learn/pandas. El análisis completo (variación de tamaño de muestra, medición de memoria con `tracemalloc`, y evaluación de complejidad) se realizó en Fase 3 y está documentado en

`F3/notebooks/S2_F3_NucleoAlgoritmico_Eficiencia_P00.ipynb`.

Aquí se replica la comparación de tiempos sobre el conjunto real de este proyecto (5.511 filas), como evidencia directa dentro del notebook consolidado.

```
In [4]: from src.medicion import medir_tiempo_timeit
from sklearn.preprocessing import StandardScaler

def escalar_propio(df, columna):
    return EscaladorEstandar(columna).ajustar_transformar(df[[columna]])

def escalar_sklearn(df, columna):
    resultado = df[[columna]].copy()
    resultado[columna] = StandardScaler().fit_transform(resultado[[columna]])
    return resultado

tiempo_propio = medir_tiempo_timeit(escalar_propio, df_transformado)
tiempo_sklearn = medir_tiempo_timeit(escalar_sklearn, df_transformado)

pd.DataFrame([
    {"implementacion": "EscaladorEstandar (propio)", "tiempo_s": tiempo_propio},
    {"implementacion": "StandardScaler (sklearn)", "tiempo_s": tiempo_sklearn}
])
```

```
Out[4]:
```

	implementacion	tiempo_s
0	EscaladorEstandar (propio)	0.000139
1	StandardScaler (sklearn)	0.000487

3.3 Verificación contra el resultado oficial de la Fase 2

```
In [5]: from src.validador import verificar_contra_fase2

RUTA_PROCESADO = RAIZ / "data" / "processed" / "ens_procesado.csv"

pipeline_verificacion = Pipeline(pasos_limpieza + pasos_integracion)
coincide = verificar_contra_fase2(
    pipeline_verificacion,
    datos,
    RUTA_PROCESADO,
    verificar_tipos=True,
)

assert coincide, "El pipeline no reproduce el resultado oficial de la Fase 2"
print("Verificado: el pipeline reproduce exactamente ens_procesado.csv")
```

[OK] El resultado coincide con la referencia: 5511 filas x 23 columnas comparadas

Verificado: el pipeline reproduce exactamente ens_procesado.csv

3.4 Validación técnica (59 pruebas)

Casos normal, límite y excepción, definidos en

`tests/casos_por_clase.py`, ejecutados directamente acá.

```
In [6]: from tests.casos_por_clase import ejecutar_pruebas
```

```

reporte = ejecutar_pruebas()
print(reporte.to_string(index=False))

```

59 pruebas: 59 OK, 0 con problemas
 clase escenario

prueba estado
 detalle

Transformador	normal	Ajustar devuelve el mismo pas o, guarda lo aprendido y transformar lo aplica.	OK
Transformador	limite	parametros entrega una copia: modificarla no altera el estado interno.	OK
Transformador	limite	transformar trabaja sobre una copia y deja intacto el DataFrame de entrada.	OK
Transformador	excepcion	transformar antes de ajustar lanza RuntimeError.	OK
		RuntimeError: _PasoDoblador(x): falta llamar a ajustar().	
Transformador	excepcion	con una columna que no existe lanza KeyError.	OK
		KeyError: "_PasoDoblador(otra): 'otra' no está en el conjunto."	
Transformador	excepcion	La clase base no se usa sola: sin aprender() lanza NotImplementedError.	OK
		NotImplementedError: Transformador no implementa aprender().	
Transformador	excepcion	parametros no se puede reasignar desde fuera (AttributeError).	OK
		AttributeError: property 'parametros' of '_PasoDoblador' object has no setter	
MarcadorNoRespuesta	normal	Pasa los códigos -888 y -9999 a nulo y anota quién no respondió.	OK
MarcadorNoRespuesta	limite	Sin códigos presentes no cambia ningún valor y la bandera queda en cero.	OK
MarcadorNoRespuesta	limite	Un nulo que ya venía en los datos no cuenta como no respuesta.	OK
MarcadorNoRespuesta	excepcion	Una columna que no existe lanza KeyError.	OK
		KeyError: "MarcadorNoRespuesta(otra): 'otra' no está en el conjunto."	
EliminadorFilasNulas	normal	Quita las filas con nulo en la columna y renumera el índice.	OK
EliminadorFilasNulas	limite	Sin nulos en la columna devuelve los mismos datos.	OK
EliminadorFilasNulas	limite	Si todas las filas son nulas queda un DataFrame vacío con sus columnas.	OK
EliminadorFilasNulas	limite	Los nulos de otras columnas no provocan que se elimine la fila.	OK
EliminadorFilasNulas	excepcion	Una columna que no existe lanza KeyError.	OK
		KeyError: "EliminadorFilasNulas(otra): 'otra' no está en el conjunto."	
PorMedia	normal	Rellena los nulos con la media de los datos presentes.	OK
PorMedia	limite	Con un único dato válido, la media es ese dato.	OK
PorMedia	excepcion	Una columna sin ningún dato lanza ValueError.	OK
		ValueError: 'x' no tiene datos para calcular la media.	

PorMediana normal Rellena los nulos con la mediana de los datos presentes. OK
 PorMediana limite Con cantidad par de datos, la mediana es el promedio de los dos centrales. OK
 PorMediana excepcion Una columna sin ningún dato lanza ValueError. OK
 ValueError: 'x' no tiene datos para calcular la mediana.
 PorModa normal Rellena los nulos con el valor más frecuente. OK
 PorModa limite Con empate entre valores, se elige el menor (igual que en la Fase 2). OK
 PorModa excepcion Una columna sin ningún dato lanza ValueError. OK
 ValueError: 'x' no tiene datos para calcular la moda.
 PorMedianaDeTramo normal Rellena con la mediana de su propio tramo y marca solo las filas rellenadas. OK
 PorMedianaDeTramo limite Una fila sin tramo queda nula y no se marca como imputada. OK
 PorMedianaDeTramo limite Si un tramo no tiene ningún monto, sus filas quedan nulas y sin marca. OK
 PorMedianaDeTramo excepcion Si la columna de tramo no existe lanza KeyError. OK
 KeyError: "'tramo' no está en el conjunto."
 ImputadorFlexible normal Sin estrategia usa la mediana y la deja guardada en sus parámetros. OK
 ImputadorFlexible normal Con cualquier estrategia se usa la misma llamada y no quedan nulos. OK
 ImputadorFlexible limite Una columna sin ningún nulo no se altera. OK
 ImputadorFlexible limite Aprende en entrenamiento y aplica a prueba con el valor del entrenamiento. OK
 ImputadorFlexible excepcion Una estrategia que no es EstrategiaImputacion lanza TypeError. OK
 TypeError: La estrategia debe ser una EstrategiaImputacion.
 ImputadorFlexible excepcion Ajustar sobre una columna sin ningún dato lanza ValueError. OK
 ValueError: 'x' no tiene datos para calcular la mediana.
 EliminatorColumna normal Quita la columna indicada y deja intactas las demás y todas las filas. OK
 EliminatorColumna limite Si es la única columna, queda una tabla sin columnas pero con sus filas. OK
 EliminatorColumna excepcion Una columna que no existe lanza KeyError. OK
 KeyError: "EliminadorColumna(IdEncuesta): 'IdEncuesta' no está en el conjunto."
 ConvertidorEntero normal Convierte una columna decimal sin nulos a entero, con los mismos valores. OK
 ConvertidorEntero limite Una columna que ya es entera queda igual. OK
 ConvertidorEntero excepcion Una columna con nulos lanza ValueError al ajustar. OK
 ValueError: ConvertidorEntero(HTA): la columna tiene nulos y no puede convertirse a entero.
 CodificadorOneHot normal Crea una columna 0/1 por categoría, quita la original y conserva las demás. OK
 CodificadorOneHot limite Con una sola categoría

presente se generan igual todas las columnas. OK

CodificadorOneHot limite Ajustado con un conjunto, a otro con menos categorías le da las mismas columnas. OK

CodificadorOneHot excepcion Un código que no está en el libro de códigos lanza ValueError al ajustar. OK

ValueError: CodificadorOneHot(Sexo): se encontraron códigos no reconocidos: [np.int64(9)]

CodificadorOneHot excepcion Un código nuevo que aparece solo al transformar también lanza ValueError. OK

ValueError: CodificadorOneHot(Sexo): se encontraron códigos no reconocidos durante la transformación: [np.int64(9)]

CodificadorOneHot excepcion Una columna sin categorías definidas lanza ValueError. OK

ValueError: CodificadorOneHot(Edad): no existe un mapeo definido para 'Edad'.

EscaladorEstandar normal Deja la columna con media 0 y desviación 1, y guarda la media y la desviación. OK

EscaladorEstandar limite Los nulos se conservan y no entran en el cálculo de la media ni la desviación. OK

EscaladorEstandar limite Aprende en entrenamiento y aplica a prueba la media y desviación del entrenamiento. OK

EscaladorEstandar excepcion Una columna constante (desviación cero) lanza ValueError. OK

ValueError: EscaladorEstandar(Edad): la desviación estándar es cero o no está definida.

EscaladorEstandar excepcion

Una columna sin ningún dato lanza ValueError. OK

ValueError: EscaladorEstandar(Edad): la desviación estándar es cero o no está definida.

Pipeline normal Encadena los pasos en orden: marca, elimina filas e imputa. OK

Pipeline limite Un pipeline sin pasos devuelve los datos sin cambios. OK

Pipeline limite Agregar un paso después de ajustar obliga a ajustar de nuevo. OK

RuntimeError: Pipeline: falta llamar a ajustar().

Pipeline limite Ajustar y transformar dejan intacto el DataFrame de entrada. OK

Pipeline excepcion Agregar algo que no es un Transformador lanza TypeError. OK

TypeError: Pipeline solo acepta Transformador; se recibió str.

Pipeline excepcion transformar antes de ajustar lanza RuntimeError. OK

RuntimeError: Pipeline: falta llamar a ajustar().

Pipeline excepcion Un paso que apunta a una columna inexistente detiene el ajuste con KeyError. OK

KeyError: "ImputadorFlexible(no_existe): 'no_existe' no está en el conjunto."

IV. Fase 4 · Conjunto interpretable para visualizar

`df_transformado` tiene la edad e IMC centrados en cero y las categóricas en one-hot — correcto para el análisis, ilegible para graficar. La solución: capturar el dato en el punto del pipeline donde ya está limpio pero todavía no se codifica ni escala, justo antes de `pasos_integracion`. Se reutilizan las mismas clases, sin duplicar lógica de limpieza.

4.1 df_visual

```
In [7]: pipeline_limpieza = Pipeline(pasos_limpieza)
df_visual = pipeline_limpieza.ajustar_transformar(datos)

print(f"df_visual: {df_visual.shape[0]} filas x {df_visual.shape[1]} columnas")
print(f"  Edad en años : {df_visual['Edad'].min():.0f} a {df_visual['Edad'].max():.0f}")
print(f"    IMC          : {df_visual['IMC'].min():.1f} a {df_visual['IMC'].max():.1f}")
```

```
df_visual: 5511 filas x 18 columnas
  Edad en años : 15 a 98
    IMC          : 14.8 a 63.5
```

4.2 Etiquetas legibles según el libro de códigos ENS

Los códigos numéricos de Sexo, Zona, diabetes (`di3`) y colesterol alto (`dis2`) se traducen a texto, según `docs/diccionario_variables.csv` y el libro de códigos F1 de la ENS 2016-2017.

```
In [8]: import numpy as np

df_visual["Sexo_txt"] = df_visual["Sexo"].map({1: "Hombre", 2: "Mujer"})
df_visual["Zona_txt"] = df_visual["Zona"].map({1: "Urbano", 2: "Rural"})
df_visual["diabetes_txt"] = df_visual["di3"].map({1: "Si", 2: "No", 3: "No sabe"})
df_visual["colesterol_txt"] = df_visual["dis2"].map({
    1: "Si, una vez", 2: "Si, mas de una vez", 3: "Nunca", 4: "No responde"})
df_visual["actividad_txt"] = df_visual["GPAQ"].map({1: "Bajo", 2: "Medio", 3: "Alto"})
df_visual["HTA_txt"] = np.where(df_visual["HTA"] == 1, "Con HTA", "Sin HTA")

TRAMOS = [0, 30, 45, 60, 75, 120]
ETIQUETAS_EDAD = ["Menos de 30", "30 a 44", "45 a 59", "60 a 74", "75 y mas"]
df_visual["grupo_etario"] = pd.cut(df_visual["Edad"], bins=TRAMOS, labels=ETIQUETAS_EDAD)
df_visual["grupo_etario"] = df_visual["grupo_etario"].cat.set_categories(ETIQUETAS_EDAD)

print("df_visual listo:", df_visual.shape[1], "columnas")
df_visual[["Edad", "grupo_etario", "Sexo_txt", "Zona_txt", "HTA_txt", "diabetes_txt", "colesterol_txt", "actividad_txt"]]
```

```
df_visual listo: 25 columnas
```

Out[8]:

	Edad	grupo_etario	Sexo_txt	Zona_txt	HTA_txt	diabetes_txt	colestero
0	25	Menos de 30	Mujer	Urbano	Sin HTA	No	N
1	20	Menos de 30	Mujer	Urbano	Sin HTA	No	N
2	85	75 o mas	Mujer	Urbano	Con HTA	No	Si, mas de

4.3 Ponderación por factor de expansión muestral

La ENS 2016-2017 tiene diseño muestral complejo, así que una tasa calculada directamente sobre los 5.511 encuestados describe a la muestra, no a la población. Para que las cifras de este informe sean comparables con las que reporta MINSAL (por ejemplo, el 27,6% de HTA citado en la introducción), las tasas se ponderan con `Fexp_F1F2p_Corr`.

Lo que sí y lo que no incluye esta ponderación. Se pondera el punto estimado (la tasa), que es lo que exige la comparabilidad con las cifras oficiales. No se estima el error estándar ni el intervalo de confianza considerando conglomerados y estratos, eso requiere métodos de varianza por diseño muestral que exceden el alcance de este curso, y queda declarado como limitación en la discusión.

In [9]:

```

assert "Fexp_F1F2p_Corr" in df_visual.columns, "Falta el ponderador"

def resumir_por(df, variable, objetivo, ponderador="Fexp_F1F2p_Corr"):
    filas = []
    for valor, grupo in df.groupby(variable, observed=True):
        tasa = np.average(grupo[objetivo], weights=grupo[ponderador])
        filas.append({variable: valor, "personas": len(grupo), "tasa": tasa})
    return pd.DataFrame(filas).set_index(variable)

# Prueba rapida con HTA
print(resumir_por(df_visual, "grupo_etario", "HTA").to_string())

```

	personas	tasa
grupo_etario		
Menos de 30	1109	1.85
30 a 44	1186	12.96
45 a 59	1392	41.26
60 a 74	1251	61.29
75 o mas	573	82.63

V. Exploración dirigida por los objetivos

Antes de pulir las figuras finales del informe, se recorren los cinco objetivos específicos con una tabla o un gráfico rápido cada uno, usando `df_visual` y `resumir_por()` ya construidos en la Parte IV. Esto deja evidencia de que los cinco fueron explorados, aunque solo tres se conviertan en figura oficial en la Parte VI.

```
In [10]: DESTACADO = "#AC212E"    # aquello sobre lo que se dirige la mirada
NEUTRO    = "#9FB6C8"    # el contexto

# Banderas binarias para diabetes y colesterol alto, necesarias para
# (di3 y dis2 no son 0/1: se simplifican a presencia/ausencia, declaro)
df_visual["diabetes"] = (df_visual["di3"] == 1).astype(int)
df_visual["colesterol_alto"] = df_visual["dis2"].isin([1, 2]).astype(int)

print("Banderas creadas: diabetes, colesterol_alto")
```


Banderas creadas: diabetes, colesterol_alto

5.1 Objetivo 1 · Prevalencia de HTA por grupo etario

```
In [11]: resumen_hta_edad = resumir_por(df_visual, "grupo_etario", "HTA")
print(resumen_hta_edad.to_string())

fig, eje = plt.subplots(figsize=(7, 4))
eje.bar(resumen_hta_edad.index.astype(str), resumen_hta_edad["tasa"])
eje.set_title("Objetivo 1: prevalencia de HTA por grupo etario")
eje.set_xlabel("Grupo etario"); eje.set_ylabel("Prevalencia de HTA")
plt.tight_layout(); plt.show()
```

	personas	tasa
grupo_etario		
Menos de 30	1109	1.85
30 a 44	1186	12.96
45 a 59	1392	41.26
60 a 74	1251	61.29
75 o mas	573	82.63




5.2 Objetivo 2 · Prevalencia de diabetes por grupo etario y zona

```
In [12]: filas = []
for (grupo, zona), sub in df_visual.groupby(["grupo_etario", "Zona_...
    tasa = np.average(sub["diabetes"], weights=sub["Fexp_F1F2p_Corr...
    filas.append({"grupo_etario": grupo, "Zona": zona, "tasa": round...
resumen_diabetes = pd.DataFrame(filas)
print(resumen_diabetes.to_string(index=False))

fig, eje = plt.subplots(figsize=(8, 4.5))
sns.barplot(data=resumen_diabetes, x="grupo_etario", y="tasa", hue="Zona",
            palette=[NEUTRO, "#5A7A94"], ax=eje) # dos tonos neutros
eje.set_title("Objetivo 2: prevalencia de diabetes por grupo etario y zona")
eje.set_xlabel("Grupo etario"); eje.set_ylabel("Prevalencia de diabetes (%)")
eje.legend(title="Zona")
plt.tight_layout(); plt.show()
```

grupo_etario	Zona	tasa	personas
Menos de 30	Rural	0.25	117
Menos de 30	Urbano	4.11	992
30 a 44	Rural	5.03	171
30 a 44	Urbano	7.42	1015
45 a 59	Rural	11.42	224
45 a 59	Urbano	13.13	1168
60 a 74	Rural	19.87	240
60 a 74	Urbano	25.45	1011
75 o mas	Rural	30.72	121
75 o mas	Urbano	23.18	452



5.3 Objetivo 3 · Nivel educacional según colesterol alto


```
In [13]: orden_colesterol = ["Nunca", "No recuerda", "Si, una vez", "Si, mas de una vez"]

resumen_educacion = (
    df_visual.groupby("colesterol_txt", observed=True)["anos_estudio_MIN"]
    .agg(personas="size", promedio="mean", mediana="median").round(2)
    .reindex(orden_colesterol)
)

# Complemento ponderado, mismo criterio que en la Figura 2 (Objetivo 2)
promedios_educacion_ponderados = {
    cat: np.average(df_visual.loc[df_visual["colesterol_txt"] == cat],
                    weights=df_visual.loc[df_visual["colesterol_txt"] == cat].personas,
                    for cat in orden_colesterol
}

fig, eje = plt.subplots(figsize=(7, 4.5))
sns.boxplot(data=df_visual, x="colesterol_txt", y="anos_estudio_MIN",
            order=orden_colesterol, color=NEUTRO, ax=eje)
eje.set_title("Objetivo 3: anios de estudio segun colesterol alto")
eje.set_xlabel("Colesterol alto"); eje.set_ylabel("Anios de estudio")
plt.tight_layout(); plt.show()

print("Promedio muestral (sin ponderar):")
print(resumen_educacion.to_string())
print("\nPromedio ponderado por Fexp_F1F2p_Corr (comparable a poblacion)")
for cat, valor in promedios_educacion_ponderados.items():
    print(f" {cat}: {valor:.2f}")
```



Promedio muestral (sin ponderar):

	personas	promedio	mediana
colesterol_txt			
Nunca	3830	10.4	12.0
No recuerda	271	9.2	10.0
Si, una vez	767	9.7	10.0
Si, mas de una vez	643	9.0	9.0


Promedio ponderado por Fexp_F1F2p_Corr (comparable a poblacion):

Nunca: 11.24
 No recuerda: 9.79
 Si, una vez: 10.33
 Si, mas de una vez: 10.10

5.4 Objetivo 4 · IMC según nivel de actividad física


```
In [14]: orden_actividad = ["Bajo", "Moderado", "Alto"]

fig, eje = plt.subplots(figsize=(7, 4.5))
sns.boxplot(data=df_visual, x="actividad_txt", y="IMC", order=orden_actividad,
            color=NEUTRO, fliersize=0, ax=eje)
np.random.seed(2026) # fija el jitter del stripplot para que la figura sea reproducible
sns.stripplot(data=df_visual.sample(min(500, len(df_visual))), random_state=2026,
              x="actividad_txt", y="IMC", order=orden_actividad,
              size=2.5, color="#0A1526", alpha=0.25, jitter=0.25, ax=eje)
eje.set_title("Objetivo 4: IMC segun nivel de actividad fisica")
eje.set_xlabel("Actividad fisica"); eje.set_ylabel("IMC")
plt.tight_layout(); plt.show()
```



5.5 Objetivo 5 · Edad, IMC y HTA estratificado por sexo (posible confusión de Simpson)

```
In [15]: grilla = sns.FacetGrid(df_visual, col="Sexo_txt", hue="HTA_txt",
                                palette=[NEUTRO, DESTACADO], height=4, aspect=1.5)
grilla.map(plt.scatter, "Edad", "IMC", alpha=0.35, s=14)
grilla.add_legend(title="Diagnostico")
grilla.set_axis_labels("Edad (anios)", "IMC")
grilla.set_titles("{col_name}")
plt.tight_layout(); plt.show()
```



Selección de las tres figuras oficiales

De los cinco objetivos explorados, se seleccionan tres para pulir como figuras del informe (Parte VI), siguiendo el hilo narrativo contexto → contraste → resolución:

1. **Objetivo 1** (HTA por grupo etario) — contexto: conecta con la cifra

nacional citada en la introducción.

2. **Objetivo 4** (IMC según actividad física) — contraste: un segundo factor de riesgo, con un tipo de gráfico distinto.
3. **Objetivo 5** (Simpson por sexo) — resolución: examina si el patrón se sostiene al estratificar, el análisis más profundo de los cinco.

Los objetivos 2 y 3 (diabetes por zona, educación y colesterol) quedan documentados acá, con tabla y gráfico propios, pero no se llevan a figura final: se prioriza profundidad de interpretación en tres relaciones por sobre cobertura superficial de las cinco.

VI. Las tres figuras del informe

De los cinco objetivos explorados en la Parte V, se pulen tres como figuras oficiales, siguiendo el hilo narrativo contexto → contraste → resolución (sección 9 de la guía de Fase 4). Cada una lleva título con el hallazgo, ejes con unidad y fuente al pie.

```
In [16]: import os

CARPETA_FIGURAS = RAIZ / "F4" / "figuras"
os.makedirs(CARPETA_FIGURAS, exist_ok=True)

def rotular(fig, eje, titulo, x, y, fuente="ENS 2016-2017, elaborac
    """Aplica el rotulado obligatorio: titulo-hallazgo, ejes con un

    Centralizarlo evita que alguna figura quede sin titulo, sin uni
    """
    eje.set_title(titulo)
    eje.set_xlabel(x)
    eje.set_ylabel(y)
    fig.text(0.01, -0.03, f"Fuente: {fuente}", fontsize=8, color="#f
    return eje

def exportar(fig, nombre_archivo):
    """Guarda la figura en F4/figuras/, para insertarla en el infor
    ruta = CARPETA_FIGURAS / nombre_archivo
    fig.savefig(ruta, dpi=200, bbox_inches="tight")
    print(f"Guardada: {ruta.relative_to(RAIZ)}")
```

Figura 1 · Objetivo 1 (contexto): prevalencia de HTA por grupo etario

```
In [17]: resumen_hta_edad = resumir_por(df_visual, "grupo_etario", "HTA")


fig, eje = plt.subplots(figsize=(8, 4.8))
```

```

colores = [DESTACADO if v == resumen_hta_edad["tasa"].max() else NEI
barras = eje.bar(resumen_hta_edad.index.astype(str), resumen_hta_edad["tasa"])
eje.bar_label(barras, fmt="%.1f%", padding=3)
rotular(fig, eje,
        "La prevalencia de HTA pasa de 1,9% en menores de 30 años a 82,6% en mayores de 75 años",
        "Grupo etario", "Prevalencia de HTA (% , ponderada)")
eje.set_ylim(0, resumen_hta_edad["tasa"].max() * 1.2)
plt.tight_layout()
exportar(fig, "figura_1_hta_por_edad.png")
plt.show()

```

Guardada: F4/figuras/figura_1_hta_por_edad.png



Fuente: ENS 2016-2017, elaboracion propia

Qué muestra. La prevalencia de HTA crece de forma sostenida con la edad: es marginal antes de los 30 años (1,9%) y alcanza a más de 8 de cada 10 personas después de los 75 (82,6%), superando el 50% ya en el tramo de 60 a 74 años.

Qué se infiere. El envejecimiento es, con distancia, el factor individual más asociado a la HTA en este conjunto, consistente con la literatura clínica y con la cifra nacional de 27,6% citada en la introducción, que agrega todos los tramos de edad.

Qué límite tiene. Es una asociación bivariada: no descarta que parte del efecto se explique por otras variables que también cambian con la edad, como el IMC (ver Figura 2) o los años de estudio.

Cómo aporta al relato. Es el acto de **contexto**: establece la magnitud del fenómeno y señala la variable que domina el análisis, antes de contrastarla con un factor modificable (Figura 2) y de someterla a una segunda verificación (Figura 3).

Figura 2 · Objetivo 4 (contraste): IMC según nivel de actividad física


```
In [18]: orden_actividad = ["Bajo", "Moderado", "Alto"]
medianas_actividad = df_visual.groupby("actividad_txt", observed=True)

# Complemento ponderado: resumir_por() solo pondera tasas 0/1, así que
# una variable continua como IMC se calcula aparte con np.average y
# ponderador, para declarar si el hallazgo se mantiene al considerar
promedios_ponderados = {
    cat: np.average(df_visual.loc[df_visual["actividad_txt"] == cat],
                    weights=df_visual.loc[df_visual["actividad_txt"] == cat].size,
                    axis=0)
    for cat in orden_actividad
}

fig, eje = plt.subplots(figsize=(7.5, 4.8))
colores_caja = {"Bajo": DESTACADO, "Moderado": NEUTRO, "Alto": NEUTRO}
sns.boxplot(data=df_visual, x="actividad_txt", y="IMC", order=orden_actividad,
            hue="actividad_txt", palette=colores_caja, legend=False)
np.random.seed(2026) # fija el jitter del stripplot para que la figura sea reproducible
sns.stripplot(data=df_visual.sample(min(500, len(df_visual))), random_state=2026,
              x="actividad_txt", y="IMC", order=orden_actividad,
              size=2.4, color="#0A1526", alpha=0.2, jitter=0.28, ax=eje)
rotular(fig, eje,
        "El IMC baja levemente a mayor actividad física: mediana de IMC por",
        "Nivel de actividad física (GPAQ)", "IMC (kg/m2)")
plt.tight_layout()
exportar(fig, "figura_2_imc_por_actividad.png")
plt.show()

print("Mediana muestral (sin ponderar):")
print(medianas_actividad.round(1).to_string())
print("\nPromedio ponderado por Fexp_F1F2p_Corr (comparable a población):")
for cat, valor in promedios_ponderados.items():
    print(f" {cat}: {valor:.2f}")
```

Guardada: F4/figuras/figura_2_imc_por_actividad.png



Fuente: ENS 2016-2017, elaboración propia

Mediana muestral (sin ponderar):

actividad_txt

Bajo 28.7

Moderado 28.1

Alto 27.9

Promedio ponderado por Fexp_F1F2p_Corr (comparable a población):

Bajo: 28.93

Moderado: 28.34

Alto: 28.26

Qué muestra. La mediana muestral de IMC baja de 28,7 en actividad baja a 28,1 en moderada y 27,9 en alta. El promedio ponderado por el factor de expansión muestra el mismo patrón (28,9 → 28,3 → 28,3), así que el hallazgo no depende de si se pondera o no, aunque el valor exacto cambia un poco entre la muestra y la estimación poblacional. La diferencia entre el extremo bajo y el alto es, en ambos casos, de menos de un punto de IMC.

Qué se infiere. Hay una asociación entre mayor actividad física y menor IMC, coherente con la evidencia clínica, pero de magnitud modesta en este conjunto: la actividad física por sí sola no separa claramente los grupos.

Qué límite tiene. GPAQ es autorreportado (no medido), y la relación observada no permite establecer causalidad: personas con IMC más alto también podrían reducir su actividad física a causa de su condición, no solo al revés. Además, el gráfico en sí (cuartiles de la caja) usa los valores muestrales sin ponderar, porque seaborn no calcula cuartiles ponderados de forma nativa; el promedio ponderado se reporta como evidencia complementaria para declarar que la conclusión se sostiene de todas formas.


Cómo aporta al relato. Es el acto de **contraste**: presenta el factor que se esperaba que compitiera con la edad —modificable, a diferencia de esta— y muestra que su efecto es real pero mucho más débil, reforzando por comparación la fuerza del hallazgo de la Figura 1.

Figura 3 · Objetivo 5 (resolución): edad, IMC y HTA, estratificado por sexo

```
In [19]: grilla = sns.FacetGrid(df_visual, col="Sexo_txt", hue="HTA_txt",
                                palette=[NEUTRO, DESTACADO], height=4.3, as
grilla.map(plt.scatter, "Edad", "IMC", alpha=0.35, s=14)
grilla.add_legend(title="Diagnostico")
grilla.set_axis_labels("Edad (años)", "IMC (kg/m2)")
grilla.set_titles("{col_name}")
grilla.figure.suptitle(
    "La relacion entre edad, IMC e hipertension se mantiene similar
    y=1.04)
grilla.figure.text(0.01, -0.03, "Fuente: ENS 2016-2017, elaboracion
exportar(grilla.figure, "figura_3_edad_imc_hta_por_sexo.png")
plt.show()

for sexo, g in df_visual.groupby("Sexo_txt"):
    tasa = np.average(g["HTA"], weights=g["Fexp_F1F2p_Corr"]) * 100
    etiqueta = "hombres" if sexo == "Hombre" else "mujeres"
    print(f"Prevalencia de HTA en {etiqueta}: {tasa:.1f}% (n={len(g
```

Guardada: F4/figuras/figura_3_edad_imc_hta_por_sexo.png



Fuente: ENS 2016-2017, elaboracion propia

Prevalencia de HTA en hombres: 27.5% (n=2017)

Prevalencia de HTA en mujeres: 27.7% (n=3494)

Qué muestra. En ambos paneles, las personas con HTA (destacadas) se concentran hacia edades mayores e IMC más alto, y el patrón visual es prácticamente el mismo en hombres que en mujeres. La prevalencia ponderada de HTA también es casi idéntica entre sexos (27,5% en hombres, 27,7% en mujeres).

Qué se infiere. No se observa una variable de confusión fuerte por sexo: la

asociación entre edad, IMC e hipertensión no cambia de dirección ni de magnitud relevante al estratificar, a diferencia de lo que ocurriría en un caso clásico de paradoja de Simpson.

Qué límite tiene. Esto descarta el sexo como confusor evidente en esta relación particular, pero no descarta que otras variables no examinadas aquí (por ejemplo, zona o nivel educacional) sí modifiquen el patrón.

Cómo aporta al relato. Es el acto de **resolución**: somete el hallazgo de la Figura 1 a una segunda verificación —la estratificación por sexo— y confirma que se sostiene, cerrando la secuencia con la inferencia más robusta de las tres.

VII. El hilo narrativo de los hallazgos

Un gráfico aislado informa; una secuencia de gráficos argumenta. Las tres figuras oficiales (Parte VI) se organizan en los tres movimientos que propone la metodología del curso.

Contexto — Figura 1. La vista global: la prevalencia de HTA asciende de forma marcada con la edad, de 1,9% a 82,6%. Esto sitúa el problema y responde la primera pregunta: ¿cuál es el panorama general?

Contraste — Figura 2. El patrón que se aparta: la actividad física se asocia al IMC en la dirección esperada, pero con una diferencia menor a un punto. Es el factor que se esperaba que compitiera con la edad, y no lo hace con la misma fuerza.

Resolución — Figura 3. La inferencia final: al estratificar por sexo, el patrón entre edad, IMC y HTA se mantiene igual en ambos grupos. Esto confirma que la edad es el eje explicativo, y no un artefacto de cómo se distribuye el sexo en la muestra. Límite: esto descarta al sexo como confusor, no a otras variables no evaluadas.

VIII. Resultados, discusión y conclusiones

8.1 Resultados

De los cinco objetivos específicos planteados en 1.4, los resultados obtenidos

—las tasas y promedios citados a continuación, ponderados por el factor de expansión `Fexp_F1F2p_Corr` (ver en 1.5 qué se pondera y qué no)— se resumen a continuación.

La prevalencia de hipertensión arterial (Objetivo 1) presenta el gradiente etario más pronunciado de todo el análisis: de 1,9% en menores de 30 años a 82,6% en mayores de 75. La prevalencia de diabetes (Objetivo 2) sigue una tendencia etaria similar, pero con un patrón que se revierte en el tramo de mayor edad, donde la zona rural (30,7%) supera a la urbana (23,2%), invirtiendo la relación observada en todos los tramos anteriores —aunque ese subgrupo rural es también el más pequeño de la muestra (n=121), lo que limita la confianza en esa cifra puntual. La relación entre escolaridad y colesterol alto (Objetivo 3) muestra un gradiente educacional descendente: 11,2 años de estudio promedio ponderado entre quienes nunca han tenido colesterol alto, contra 10,1 años entre quienes lo han tenido en más de una ocasión. La asociación entre actividad física e IMC (Objetivo 4) es consistente en dirección, pero modesta en magnitud (28,9 a 28,3 de IMC promedio ponderado). Y la estratificación por sexo de la relación edad-IMC-HTA (Objetivo 5) no evidencia confusión: 27,5% de prevalencia en hombres contra 27,7% en mujeres.

8.2 Discusión

Contraste con las hipótesis iniciales. La pregunta de investigación (1.2) suponía una relación entre cinco condiciones sociodemográficas y cinco indicadores de riesgo, sin anticipar cuál pesaría más. Los resultados muestran que esa relación está lejos de ser homogénea: la edad concentra, con amplio margen, la asociación más fuerte y más robusta del conjunto, mientras que escolaridad y zona aparecen como factores secundarios —con señales reales, pero de menor solidez estadística— y el sexo queda descartado como variable de confusión relevante para el hallazgo principal.

Comparación con la literatura y con la cifra oficial. El patrón etario encontrado para HTA es consistente con lo descrito en la literatura epidemiológica sobre hipertensión, que atribuye su aumento con la edad a cambios estructurales del sistema vascular. La cifra nacional de 27,6% (MINSAL), citada en la introducción, resulta de promediar tramos con riesgos muy distintos entre sí (de 1,9% a 82,6%): es una cifra útil para comparación con política pública agregada, pero oculta la heterogeneidad que este análisis expone.

Limitaciones y riesgos. Ninguna de las diferencias reportadas cuenta con una prueba de significancia estadística formal, porque la ponderación aplicada corrige solo el sesgo de selección de la muestra respecto a la población, sin

incorporar la estructura de conglomerados y estratos del diseño muestral de la ENS (declarado en 1.5). El diseño transversal del estudio impide, además, establecer causalidad o secuencia temporal entre las condiciones sociodemográficas y los indicadores de riesgo: por ejemplo, no es posible determinar si un IMC más alto reduce la actividad física reportada, o si es al revés. El hallazgo sobre diabetes rural en el tramo de mayor edad (Objetivo 2) es el que enfrenta mayor riesgo de inestabilidad, dado su reducido tamaño muestral.

8.3 Conclusiones

El objetivo general (1.3) se cumple de forma parcial: existe relación entre las condiciones sociodemográficas evaluadas y los indicadores de riesgo cardiovascular, pero no con el mismo peso entre ellas. La edad se consolida como el eje explicativo dominante para la hipertensión arterial, una conclusión que resiste dos verificaciones exigentes —el contraste con un factor modificable y la estratificación por una variable candidata a confusión—, mientras que escolaridad, zona de residencia y actividad física aportan evidencia complementaria de menor magnitud.

En términos de mejoras basadas en esta evidencia, el hallazgo etario sugiere priorizar el tamizaje de HTA desde los 45-59 años, tramo donde la prevalencia ya supera el 40%; la brecha rural-urbana detectada en diabetes en el tramo de mayor edad amerita un estudio específico con mayor tamaño muestral antes de derivar en recomendaciones de política; y, para trabajos futuros con este mismo conjunto, incorporar el diseño muestral completo permitiría declarar significancia estadística formal en lugar de diferencias exclusivamente descriptivas.

IX. Trazabilidad de mejoras

Evidencia de que el proyecto evolucionó por decisiones y no por acumulación. Cada fila indica qué se observó, qué se hizo, qué impacto tuvo y dónde quedó registrado (commit o pull request del repositorio), de modo que cualquier mejora puede rastrearse en GitHub.

9.1 Registro de mejoras por fase

Esta celda construye la tabla `mejoras`, que reúne las once mejoras principales del proyecto, de la Fase 1 a la Fase 4. Cada fila indica la fase, el

problema observado (propio o señalado en la retroalimentación docente), la acción tomada, su impacto y la evidencia que lo respalda (sección, commit o pull request), de modo que cada cambio pueda justificarse y rastrearse en GitHub. Antes de mostrarla, se configura pandas para que los textos largos aparezcan completos.

```
In [20]: pd.set_option("display.max_colwidth", None)

mejoras = pd.DataFrame([
    {"fase": "F1 a F2",
     "observacion": "GPAQ se había declarado nominal en la Fase 1",
     "accion": "Se reclasificó como ordinal (Bajo < Moderado < Alto)",
     "impacto": "Conserva el orden de la escala; permite la Figura 1",
     "evidencia": "F2, sección 5"},
    {"fase": "F2",
     "observacion": "El código -9999 de as28 se leía como un ingreso",
     "accion": "Se detectó variable por variable y se convirtió en 0",
     "impacto": "818 casos detectados (816 tras excluir las 9 filas)",
     "evidencia": "commit d97ce95"},
    {"fase": "F2",
     "observacion": "as27 y as28 comparten la misma no respuesta ec",
     "accion": "Imputación parcial de as27 por la mediana de su tra",
     "impacto": "No se inventan ingresos; la limitación queda decla",
     "evidencia": "commits c2b766f y 5c73c95"},
    {"fase": "F2 a F3",
     "observacion": "Retroalimentación: la base original (13,6 MB) c",
     "accion": "Se dejó de versionar ens2016.xlsx y se declaró ens_",
     "impacto": "Repositorio liviano y sin ambigüedad sobre qué arcl",
     "evidencia": "commits f0f312d y e7c2ab7 (PR #20)"},
    {"fase": "F3",
     "observacion": "Retroalimentación: iterrows frente a .iloc med",
     "accion": "Se agregó la búsqueda real por clave, la medición de",
     "impacto": "La decisión de usar set_index quedó fundamentada co",
     "evidencia": "commit 0beaeb0 (PR #2)"},
    {"fase": "F3",
     "observacion": "construir_indice_dict usaba iterrows e inflaba",
     "accion": "Se reescribió con dict(zip(...)) y se repitió la co",
     "impacto": "Umbral corregido a menos de una búsqueda frente a",
     "evidencia": "commit 2ca4310 (PR #25)"},
    {"fase": "F2 a F3",
     "observacion": "El preprocesamiento estaba en funciones suelta",
     "accion": "Clase base Transformador, siete pasos, patrón Strate",
     "impacto": "Un paso nuevo no obliga a modificar el Pipeline; re",
     "evidencia": "commits 12829fa, 352e2ae y 65b9e6d (PR #8 a #11)"},
    {"fase": "F3",
     "observacion": "Las pruebas vivían dentro de validador.py",
     "accion": "Se separaron en tests/ (59 por clase y 13 de transfo",
     "impacto": "72 pruebas aprobadas; la parte III ejecuta las 59 c",
     "evidencia": "commits 3453e13 y 366920b (PR #19)"},
    {"fase": "F3 a F4",
     "observacion": "El conjunto procesado (escalado y one-hot) era",
     "accion": "df_visual se captura del pipeline antes de codifica",
     "impacto": "Figuras en unidades reales (años, kg/m2) sin dupli",
     "evidencia": "commit 0ba9908 (PR #29)"},
```

```

{"fase": "F4",
 "observacion": "Las tasas describían la muestra, no la población",
 "accion": "Se ponderan con Fexp_F1F2p_Corr y se declara qué se",
 "impacto": "HTA 27,6 %, igual a la cifra oficial de MINSAL",
 "evidencia": "commits 0ba9908, 56c161b y 7877193 (PR #29, #31)",
}
{"fase": "F4",
 "observacion": "Cinco objetivos explorados, sin jerarquía entre",
 "accion": "Se seleccionaron tres figuras con hilo contexto, con",
 "impacto": "El informe argumenta en lugar de solo describir",
 "evidencia": "commits 30c8b23 y 4546205 (PR #30 y #33)"},
]
)

mejoras

```

Out[20]:

	fase	observacion	accion	impacto	evidencia
--	------	-------------	--------	---------	-----------

0	F1 a F2	GPAQ se había declarado nominal en la Fase 1	Se reclasificó como ordinal (Bajo < Moderado < Alto) y se conservó como entero, sin one-hot	Conserva el orden de la escala; permite la Figura 2 (Objetivo 4)	F2 sección 1
1	F2	El código -9999 de as28 se leía como un ingreso válido	Se detectó variable por variable y se convirtió en nulo con la bandera as28_no_responde	818 casos detectados (816 tras excluir las 9 filas sin HTA) dejan de contaminar las estadísticas; la no respuesta queda registrada	commit d97ce9!
2	F2	as27 y as28 comparten la misma no respuesta económica (816 personas)	Imputación parcial de as27 por la mediana de su tramo (177 casos); 816 faltantes genuinos documentados	No se inventan ingresos; la limitación queda declarada	commit c2b766f · 5c73c9!
3	F2 a F3	Retroalimentación: la base original (13,6 MB) estaba versionada	Se dejó de versionar ens2016.xlsx y se declaró ens_procesado.csv como archivo vigente	Repositorio liviano y sin ambigüedad sobre qué archivo usar	commit f0f312d · e7c2ab (PR #20)
4	F3	Retroalimentación: iterrows frente a .iloc medía acceso por posición, no una búsqueda	Se agregó la búsqueda real por clave, la medición de memoria y el punto de equilibrio	La decisión de usar set_index quedó fundamentada con mediciones	commit 0beaeb (PR #2)
5	F3	construir_indice_dict usaba iterrows e inflaba el umbral (437 búsquedas)	Se reescribió con dict(zip(...)) y se repitió la comparación	Umbral corregido a menos de una búsqueda frente a iterrows	commit 2ca431 (PR #25)
			Clase base	Un paso nuevo no	commit

6	F2 a F3	El preprocesamiento estaba en funciones sueltas con ramas if	Transformador, siete pasos, patrón Strategy en la imputación y Pipeline	obliga a modificar el Pipeline; reproduce exacto ens_procesado.csv (parte III)	12829fa352e2a 65b9e6 (PR #8 #11
7	F3	Las pruebas vivían dentro de validador.py	Se separaron en tests/ (59 por clase y 13 de transformadores), ejecutables con pytest	72 pruebas aprobadas; la parte III ejecuta las 59 dentro del notebook	commit 3453e1 366920 (PR #19
8	F3 a F4	El conjunto procesado (escalado y one-hot) era ilegible para graficar	df_visual se captura del pipeline antes de codificar y escalar, con etiquetas del libro de códigos	Figuras en unidades reales (años, kg/m2) sin duplicar la lógica de limpieza	commi 0ba990 (PR #29
9	F4	Las tasas describían la muestra, no la población (HTA 36,3 %)	Se ponderan con Fexp_F1F2p_Corr y se declara qué se pondera y qué no	HTA 27,6 %, igual a la cifra oficial de MINSAL	commit 0ba990856c161 787719 (PR #29 #31 #33
10	F4	Cinco objetivos explorados, sin jerarquía entre ellos	Se seleccionaron tres figuras con hilo contexto, contraste y resolución	El informe argumenta en lugar de solo describir	commit 30c8b2 454620 (PR #30 #33

9.2 Impacto verificable en esta ejecución

Esta celda recalcula en vivo las cifras que respaldan las mejoras de mayor peso: la prevalencia de HTA sin ponderar y ponderada por

`Fexp_F1F2p_Corr` (comparada con el 27,6% de MINSAL), si el pipeline reproduce el resultado oficial de la Fase 2, cuántas de las 59 pruebas por clase se aprobaron y cuántos casos quedaron marcados como no respuesta en `as28` o imputados por tramo en `as27`. Así, el impacto declarado en 9.1 no depende de cifras escritas a mano. Como reutiliza resultados de las partes III y IV, debe ejecutarse después de ellas, idealmente con **Run All**.

```
In [21]: tasa_muestra = df_visual["HTA"].mean() * 100
tasa_ponderada = np.average(df_visual["HTA"], weights=df_visual["Fe

print("IMPACTO VERIFICABLE EN ESTA EJECUCIÓN")
print("=" * 58)
print(f" HTA sin ponderar (muestra)      : {tasa_muestra:.1f}%")
```

```
print(f" HTA ponderada (población)      : {tasa_ponderada:.1f}% (M
print(f" Pipeline reproduce la Fase 2  : {coincide}")
print(f" Pruebas por clase aprobadas    : {(reporte['estado'] == 'O
print(f" as28 con no respuesta marcada : {int(df_visual['as28_no_r
print(f" as27 imputadas por tramo       : {int(df_visual['as27_imp
```

IMPACTO VERIFICABLE EN ESTA EJECUCIÓN

=====

```
HTA sin ponderar (muestra)      : 36.3%
HTA ponderada (población)      : 27.6% (MINSAL: 27,6%)
Pipeline reproduce la Fase 2   : True
Pruebas por clase aprobadas    : 59 de 59
as28 con no respuesta marcada  : 816
as27 imputadas por tramo       : 177
```

9.3 Registro de cambios (changelog)

Esta celda lee el archivo `F4/changelog.md` y muestra su contenido completo; si el archivo no existe, se detiene con un mensaje claro. El changelog ordena por fase y fecha las mismas mejoras de 9.1, con los commits, el pull request y la persona responsable de cada una, y al leerse directamente desde el repositorio, el notebook siempre muestra su versión más reciente.

```
In [22]: RUTA_CHANGELOG = RAIZ / "F4" / "changelog.md"
assert RUTA_CHANGELOG.exists(), "Falta F4/changelog.md"
print(RUTA_CHANGELOG.read_text(encoding="utf-8"))
```

Changelog · proyecto-grupo4-mcdi500

Registro cronológico de las mejoras del proyecto, de la Fase 1 a la Fase 4. Cada entrada corresponde a una fila de la tabla de la sección IX (Trazabilidad de mejoras) del notebook ``F4/notebooks/S3_F4_Consolidado.ipynb`` e indica los commits y pull requests (PR) donde puede verificarse en GitHub.

Fase 1 a Fase 2 · Preparación de datos

GPAQ reclasificada de nominal a ordinal

- Observación: GPAQ se había declarado nominal en la Fase 1.
- Cambio: se trata como ordinal (Bajo < Moderado < Alto) y se conserva como entero, sin one-hot.
- Evidencia: F2, sección 5.

2026-09-12 · Código -9999 de as28 tratado como no respuesta

- Observación: el código -9999 de as28 se leía como un ingreso válido.
- Cambio: se identifican los códigos especiales de no respuesta variable por variable; en as28 se convierten en nulo y se registran en la bandera ``as28_no_respon`

de` (818 casos detectados;

816 en el conjunto final, tras excluir las 9 filas sin HTA).

- Commit: d97ce95 (Felipe Díaz Toro), incorporado en el PR #1.

2026-09-15 · Imputación parcial de as27 por tramo de ingreso

- Observación: as27 y as28 comparten la misma no respuesta económica (816 personas).

- Cambio: as27 se imputa con la mediana de su tramo as28 solo cuando el tramo es conocido

(177 casos); los 816 faltantes genuinos se conservan y quedan documentados.

- Commits: c2b766f (Ninoska Yévenes Hernández) y 5c73c95 (Felipe Díaz Toro), incorporados en el PR #1.

Fase 2 a Fase 3 · Repositorio y orientación a objetos

2026-09-24 · Preprocesamiento reescrito con clases y Pipeline

- Observación: el preprocesamiento estaba en funciones sueltas con ramas if.

- Cambio: clase base `Transformador`, siete pasos de preprocesamiento, patrón Strategy en la

imputación y clase `Pipeline` que los encadena.

- Commits: 12829fa (Felipe Díaz Toro, PR #8), 65b9e6d (Felipe Díaz Toro, PR #10) y

352e2ae (Ninoska Yévenes Hernández, PR #11).

2026-09-25 / 2026-09-26 · Base original fuera del control de versiones

- Observación (retroalimentación): la base original ens2016.xlsx (13,6 MB) estaba versionada.

- Cambio: se deja de versionar ens2016.xlsx y se declara `data/procesado/ens\_procesado.csv` como archivo vigente.

- Commits: f0f312d y e7c2ab7 (Felipe Díaz Toro), incorporados en el PR #20.

Fase 3 · Núcleo algorítmico, eficiencia y pruebas

2026-09-23 · Medición de eficiencia corregida según retroalimentación

- Observación (retroalimentación): la comparación iterrows frente a .iloc medía acceso por

posición, no una búsqueda.

- Cambio: se agrega la búsqueda real por clave, la medición de memoria y el punto de

equilibrio; las funciones de medición pasan a `src/medicion.py`.

- Commit: 0beaeb0 (Felipe Díaz Toro), PR #2.

2026-09-26 · Pruebas separadas en tests/

- Observación: las pruebas vivían dentro de `src/validador.py`.

- Cambio: se separan en `tests/` (59 pruebas por clase y 13 de transformadores), ejecutables

con pytest; 72 pruebas aprobadas.

- Commits: 3453e13 y 366920b (Pablo Ríos Passteni), PR #19.

2026-09-27 · Índice por diccionario sin iterrows

- Observación: `construir\_indice\_dict` usaba iterrows e inflaba el punto de equilibrio (437 búsquedas).
- Cambio: se reescribe con `dict(zip(...))` y se repite la comparación; el punto de equilibrio queda en menos de una búsqueda frente a iterrows.
- Commit: 2ca4310 (Felipe Díaz Toro), PR #25.

Fase 3 a Fase 4 · Visualización y comunicación

2026-09-29 · Conjunto interpretable df_visual

- Observación: el conjunto procesado (escalado y one-hot) era ilegible para graficar.
- Cambio: `df\_visual` se captura del pipeline antes de codificar y escalar, con etiquetas según el libro de códigos ENS; las figuras quedan en unidades reales (años, kg/m²).
- Commit: 0ba9908 (Felipe Díaz Toro), PR #29.

2026-09-29 / 2026-09-30 · Ponderación por factor de expansión

- Observación: las tasas describían la muestra, no la población (HTA 36,3 %).
- Cambio: las tasas se ponderan con `Fexp\_F1F2p\_Corr` (HTA 27,6 %, igual a la cifra oficial de MINSAL); se agrega el complemento ponderado a la Figura 2 y se declara qué se pondera y qué no (secciones 1.5 y 8.1).
- Commits: 0ba9908 (Felipe Díaz Toro, PR #29), 56c161b (Ninoska Yévenes Hernández, PR #31) y 7877193 (Ninoska Yévenes Hernández, PR #33).

2026-09-30 · Selección de tres figuras con hilo narrativo

- Observación: cinco objetivos explorados, sin jerarquía entre ellos.
- Cambio: se seleccionan tres figuras oficiales con el hilo contextual, contraste y resolución, y cada interpretación explica cómo aporta al relato.
- Commits: 30c8b23 (PR #30) y 4546205 (PR #33), ambos de Ninoska Yévenes Hernández.

Qué muestra esta parte. Las mejoras no fueron acumulativas: cada una responde a una observación concreta (propia o de la retroalimentación docente) y deja una evidencia rastreable. La de mayor impacto es la ponderación: sin ella, la prevalencia de HTA (36,3 %) habría sobrestimado la cifra poblacional (27,6 %) en casi nueve puntos.

X. Exportación y verificación final

Antes de dar por cerrado el cuaderno, se verifica que todo lo que el informe va a citar realmente existe y es reproducible: las figuras exportadas, el pipeline, las pruebas, el changelog y las decisiones declaradas.

```
In [23]: from pathlib import Path
import hashlib

def huella(ruta):
    """Huella SHA-256 (16 caracteres) de un archivo, para verificar
    h = hashlib.sha256()
    with open(ruta, "rb") as f:
        for bloque in iter(lambda: f.read(8192), b''):
            h.update(bloque)
    return h.hexdigest()[:16]

CARPETA_FIGURAS = RAIZ / "F4" / "figuras"
ARCHIVOS_FIGURAS = [
    CARPETA_FIGURAS / "figura_1_hta_por_edad.png",
    CARPETA_FIGURAS / "figura_2_imc_por_actividad.png",
    CARPETA_FIGURAS / "figura_3_edad_imc_hta_por_sexo.png",
]

print("ARTEFACTOS DEL PROYECTO")
print("=" * 62)
for ruta in ARCHIVOS_FIGURAS:
    if ruta.exists():
        print(f" {ruta.name:42} {huella(ruta)} ({ruta.stat().st_size:10})")
    else:
        print(f" {ruta.name:42} FALTA")

ruta_changelog = RAIZ / "F4" / "changelog.md"
print(f" {'changelog.md':42} {'OK' if ruta_changelog.exists() else 'FALTA'}
```

ARTEFACTOS DEL PROYECTO

```
=====
figura_1_hta_por_edad.png          15df1b98eb77c5d2 (77 KB)
figura_2_imc_por_actividad.png     89ad5a90cffd30cd (72 KB)
figura_3_edad_imc_hta_por_sexo.png a52f17c0b1187c82 (562 KB)
changelog.md                       OK
```

```
In [24]: verificacion = [
    ("Las tres figuras oficiales existen en F4/figuras/", all(r.exists() for r in ARCHIVOS_FIGURAS)),
    ("El pipeline reproduce exactamente ens_procesado.csv", coincide(ens_procesado.csv, ens_reproducido.csv)),
    ("Las 59 pruebas por clase pasan", (reporte["estado"] == "OK")),
    ("El changelog.md existe y es legible", ruta_changelog.exists() and ruta_changelog.read_text().strip()),
    ("La ponderación por factor de expansión está declarada (1.5 y 1.2)", "1.5" in decisiones),
    ("Se declaró el límite de no causalidad y de varianza por diseño", "no causalidad" in decisiones),
    ("El notebook corrió de principio a fin con Restart and Run All Cells"),
]
```

```

print("VERIFICACIÓN FINAL DEL CUADERNO")
print("=" * 62)
for titulo, estado in verificacion:
    print(f" [{ 'OK' if estado else 'FALTA' }] {titulo}")

aprobados = sum(1 for _, e in verificacion if e)
print(f"\n{aprobados} de {len(verificacion)} comprobaciones aprobadas")

```

VERIFICACIÓN FINAL DEL CUADERNO

```

=====
[OK] Las tres figuras oficiales existen en F4/figuras/
[OK] El pipeline reproduce exactamente ens_procesado.csv
[OK] Las 59 pruebas por clase pasan
[OK] El changelog.md existe y es legible
[OK] La ponderación por factor de expansión está declarada (1.5 y
4.3)
[OK] Se declaró el límite de no causalidad y de varianza por diseño
o muestral
[OK] El notebook corrió de principio a fin con Restart and Run All

7 de 7 comprobaciones aprobadas

```

Cierre

Lo que este cuaderno demuestra

Criterio del entregable	Dónde está en este cuaderno
Reproducibilidad técnica	Registro del entorno, Parte 0
Programación orientada a objetos	Jerarquía Transformador y Pipeline , Parte III
Diseño estructurado	Cada transformador con una responsabilidad, Parte III
Validación técnica	59 pruebas por clase, Parte III
Eficiencia y optimización	Comparación EscaladorEstandar vs. StandardScaler , Parte III
Preprocesamiento del dataset	Decisiones documentadas, Parte II
Preprocesamiento para visualizar	df_visual con unidades interpretables, Parte IV
Visualizaciones analíticas	Tres figuras, contexto/contraste/resolución, Parte VI
Metodología	El recorrido completo de F1 a F4
Resultados, discusión y conclusiones	Parte VIII

La cadena completa

El proyecto empezó con una pregunta sobre qué condiciones sociodemográficas se asocian a los indicadores de riesgo cardiovascular en la ENS 2016-2017, y termina con tres figuras que responden esa pregunta con un hallazgo central: la edad domina la asociación con HTA, un resultado que se sostiene frente a un factor modificable y frente a una variable candidata a confusión.

Entre medio, la Fase 2 produjo un conjunto confiable y documentado, la Fase 3 convirtió el procesamiento en componentes verificables y medidos, y la Fase 4 tradujo ese trabajo en un argumento comunicable, con cada afirmación respaldada por una cifra que se puede recalcular en este mismo cuaderno.